


Задача А3. HyperMegaLogLog Pro Max++

$B=12$ выбран после тестов с $B = 8, 10, 12, 14$ на потоках 20тыс- 50тыс элементов.

$m = 2^{12} = 4096$ регистров обеспечивает баланс: теоретическая относительная ошибка $\frac{1.04}{\sqrt{m}} \approx 1.62\%$ (нижняя граница) и $\frac{1.3}{\sqrt{m}} \approx 2.03\%$ (верхняя), память ~ 4 KB.

Меньшее B (10) давало ошибку $\sim 3 - 4\%$ с высокой дисперсией, большее (14) — $\sim 1\%$, но избыточную память (16 KB) для $n \leq 100$ тыс.

Анализ результатов работы стандартного алгоритма HyperLogLog



1. Точность разработанного алгоритма

Теоретические границы (для выбранного параметра $B = 12 \Rightarrow m = 4096$):

- 1.62% (строгая граница)
- 2.03% (слабая граница)

Практические результаты:

- Средняя относительная ошибка: 0.23%
- Максимальная относительная ошибка: 0.89%
- 100% измерений уложились в обе теоретические границы

Практическая точность (0.23%) более чем в 7 раз лучше строгой теоретической границы (1.62%) и в 9 раз лучше слабой границы (2.03%).

График №1 подтверждает высокую точность: линии $F_0^{t,t}$ (точное) и N_t (HyperLogLog) практически совпадают на всём диапазоне от 10% до 100% обработки потока. Отсутствуют

какие-либо отклонения или смещения оценки. Алгоритм одинаково хорошо работает как на малых (10%), так и на больших (100%) частях потока.

2. Стабильность оценки (дисперсия)

Результаты:

- Стандартное отклонение σ_{N_i} : 19994 элементов
- Относительное стандартное отклонение: $\sim 86\%$ от среднего значения $E(N_i)$

График №2 показывает: среднее $E(N_i)$ растёт с увеличением обработанной части потока, область $\pm \sigma_{N_i}$ широкая, но симметричная, отсутствуют какие-либо смещения или асимметрии в распределении ошибок. Но несмотря на большую дисперсию, средняя ошибка мала (0.23%), что означает: в среднем алгоритм даёт правильное значение, хотя отдельные оценки могут сильно отклоняться.

3. Эффективность выбранных констант и их влияние

Выбранные константы алгоритма HyperLogLog — $B = 12$, $L = 32$ и корректировочный коэффициент α — обеспечили оптимальный баланс между точностью и потреблением памяти. При размере регистрового массива ($m = 4096$) теоретическая ошибка составила около 1,62%, но на практике результаты показали среднюю относительную ошибку всего 0,23%, что существенно ниже теоретического предела. Использование 32-битных хешей и стандартной формулы коррекции смещения позволило минимизировать систематические искажения оценки. В результате алгоритм демонстрирует высокую стабильность и предсказуемость при различных объёмах данных. Это компромисс между точностью и ресурсами.

Анализ результатов работы стандартного алгоритма HyperMegaLogLog Pro Max++

Ключевые изменения:

1. Замена `std::vector<uint8_t>` на `std::bitset` для хранения регистров
2. Упаковка регистров: каждый регистр хранится в 5 битах вместо 8 бит (так как значения r редко превышают 32)
3. Эмпирическая коррекция смещения для диапазона $[m, 5m]$

Ресурсы:

1. <https://algo.inria.fr/flajolet/Publications/FIFuGaMe07.pdf> — формулы коррекции смещения, теоретические границы ошибки
2. <https://static.googleusercontent.com/media/research.google.com/en//pubs/archive/40671.pdf> — идеи по оптимизации памяти

Потребление памяти

Алгоритм	Структура данных	Объём памяти	Экономия
Стандартный HyperLogLog	<code>std::vector<uint8_t>(4096)</code>	4096 байт (4.0 КБ)	—
Улучшенный HyperMegaLogLogProMax++	<code>std::bitset<20480></code>	2560 байт (2.5 КБ)	37.5%

Анализ графиков




График №1: линии практически совпадают на всём диапазоне от 10% до 100%, отсутствуют систематические отклонения или смещения оценки, алгоритм работает стабильно как на малых (10%), так и на больших (100%) частях потока, качество оценки визуально неотличимо от стандартного алгоритма.

График №2: среднее $E(N_t)$ устойчиво растёт с увеличением обработанной части потока, область $E(N_t) \pm \sigma N_t$ широкая, но симметричная относительно среднего, диапазон неопределённости сравним со стандартным алгоритмом, отсутствуют асимметрии в распределении ошибок.

Сравнительная таблица

Показатель	Стандартный HyperLogLog	Улучшенный HyperMegaLogLogProMax++	Изменение
Память	4096 байт (4.0 КБ)	2560 байт (2.5 КБ)	-37.5%
$E(N_t)$	23191	23154	-37
σN_t	19994 элементов	20085 элементов	+0.5%
Средняя ошибка	0.23%	0.34%	+0.11%
Максимальная ошибка	0.89%	1.30%	+0.41%
Соответствие $\frac{1.04}{\sqrt{m}}$	10/10 (100%)	10/10 (100%)	Без

Показатель	Стандартный HyperLogLog	Улучшенный HyperMegaLogLogProMax++	Изменение
Соответствие $\frac{1.3}{\sqrt{m}}$	10/10 (100%)	10/10 (100%)	Без

Преимущества:

- Значительная экономия памяти
- Сохранение высокой точности по сравнению с теоретическими 1.62%
- 100% соответствие теоретическим границам — алгоритм предсказуем

Недостатки:

- Незначительное ухудшение точности (0.23% → 0.34%)
- Небольшой рост максимальной ошибки (0.89% → 1.30%)